

PENERAPAN *DEEP LEARNING* DAN *REINFORCEMENT LEARNING* DENGAN METODE *CONVOLUTIONAL NEURAL NETWORK* (CNN) UNTUK PENGISIAN MOBIL LISTRIK (*ELECTRIC VEHICLE*) DI JARINGAN PINTAR

Hendro Gunawan¹

¹Jurusan PJJ Informatika, Fakultas Ilmu Teknik Komputer, Universitas Siber Asia (UNISA), Jakarta, Indonesia

Info Artikel

Sejarah artikel:

Received 06 02, 2024

Revised 06 02, 2024

Accepted 10 02, 2024

Kata kunci:

Adaptive neuro-fuzzy inference system;

Deep learning;

Electric vehicles;

Gated recurrent units;

Long short-term memory neural network;

Short-term load forecasting;

ABSTRAK

Dalam penelitian ini, beberapa algoritma *Deep Learning* dan *Machine Learning* unggulan diterapkan dalam meramalkan profil beban pengisian kendaraan listrik (*electric vehicle*) dari kumpulan data nyata jaringan listrik di negara *Spain*. Studi ini bertujuan untuk menyediakan dataset realistis profil beban kendaraan listrik untuk mengatasi potensi peningkatan penetrasi kendaraan listrik dengan mempertimbangkan efek dari musim. Masalah teknis disebabkan oleh jaringan distribusi listrik, seperti daya pengisian yang besar dan perilaku pengisian stokastik dari pengemudi kendaraan listrik karena peluncuran massal kendaraan kendaraan listrik. Peramalan profil beban kendaraan listrik diperlukan untuk menghadapi tantangan untuk memecahkan masalah potensi peluncuran massal kendaraan listrik. Namun, kendaraan listrik dianggap sebagai salah satu solusi paling menjanjikan yang berkembang lebih cepat dari pada solusi terbarukan stokastik lainnya untuk mengurangi emisi gas rumah kaca. Efek musim yang terjadi adalah salah satu tantangan pada beban listrik, sehingga diselidiki dengan empat jaringan peramalan terpisah untuk meningkatkan akurasi sistem dan mempelajari efek faktor musim seperti fluktuasi suhu di empat musim yang mempengaruhi baterai kendaraan listrik dalam mode pengisian dan penggunaan. Faktor-faktor ini mempengaruhi akurasi model peramalan. Empat algoritma unggulan yang diterapkan diantaranya adalah *Artificial Neural Networks* (ANNs), dan *Adaptive Neuro-Fuzzy Inference Systems* (ANFIS) diterapkan sebagai algoritma *Machine Learning*, sedangkan *Long Short-Term Memory* (LSTM) dan *Gated Recurrent Units* (GRU) digunakan sebagai algoritma *Deep Learning*. Model *Gated Recurrent Unit* berkinerja sedikit lebih baik dari pada *Long Short-Term Memory* (LSTM) yang digunakan pada data historis harian rata-rata per jam untuk pengisian kendaraan listrik. Sementara Sistem Inferensi Neuro-Fuzzy Adaptif mengungguli *Artificial Neural Network* dan *System Inferensi Fuzzy*.

This is an open access article under the [CC BY-SA](#) license.



Corresponding Author:

Hendro Gunawan


PJJ Informatika, Fakultas Ilmu Teknik Komputer, Universitas Siber Asia (UNSIASIA)

Kampus Menara, JL RM Harsono, Ragunan – Jakarta Selatan Daerah Khusus Ibukota Jakarta 12550 Telp. (+6221) 27806189

Email: hendro.gnwn@gmail.com

1. PENDAHULUAN

Langkah penting menuju pengurangan emisi gas rumah kaca (GRK) adalah penggunaan sumber energi terbarukan terutama di sektor elektrifikasi transportasi. Investasi besar-besaran dalam elektrifikasi transportasi dilakukan oleh pemerintah. Menurut *International Energy Agency* (IEA) pada tahun 2018, lebih dari 5,1 juta pengemudi kendaraan listrik (*electric vehicle*) secara global dipertimbangkan dalam mobilitas listrik di jalan. Kendaraan listrik (*electric vehicle*) menyediakan bauran energi rendah karbon. Alternatif yang kredibel untuk (*electric vehicle*) mendukung sektor transportasi dalam transisi karbon yang lebih rendah daripada mobil yang menggunakan bahan bakar ber standar *Internal Combustion Engine Vehicle* (ICEV). Pada tahun 2019, hal ini menyumbang sekitar 47% pencemaran CO₂ di beberapa negara. Selain itu, tingginya kadar karbon yang dihasilkan oleh kendaraan berbahan bakar menyebabkan pencemaran lingkungan, sehingga dibutuhkan alternatif energi bahan bakar terbarukan.



Gambar 1.1. Komunikasi dua arah di *smart grid*.

Perjanjian Paris yang dipresentasikan oleh Perserikatan Bangsa-Bangsa (PBB), direkomendasikan pada tahun 2016 lalu bahwa target utamanya adalah membatasi suhu universal sebesar dua derajat *Celcius*. Sektor transportasi berbagi dengan tingkat tinggi dalam proses mengurangi dekarbonisasi dalam sistem tenaga. Baru-baru ini, tren tersebut secara langsung mengarah pada elektrifikasi kendaraan di sektor transportasi. Akibatnya, pada tahun 2019, lebih dari 2 juta kendaraan terjual, dan diharapkan pada tahun 2030, kendaraan listrik berkembang hingga mencapai hampir 350 juta kendaraan. Oleh karena itu, beberapa masalah telah disebabkan karena penetrasi skala besar kendaraan listrik seperti menyeimbangkan beban dan merencanakan kapasitas. Teknik respons permintaan mencoba memecahkan masalah ini dan mengoptimalkan strategi pengisian daya untuk menjadwalkan beban kendaraan listrik sesuai dengan harga terendah. Namun, teknik ini memberikan kinerja dan akurasi tinggi. Banyak faktor yang masih belum dipertimbangkan seperti pemodelan kebiasaan permintaan pengisian kendaraan listrik penumpang. Faktor empat musim memiliki dampak besar pada profil beban pengisian kendaraan listrik. Dalam studi terbaru, ditemukan bahwa musim, faktor musiman, harga listrik, dan infrastruktur pengisian lokal dapat mempengaruhi perilaku pengisian penumpang kendaraan listrik. *Zhao et al.* menganalisis faktor-faktor ini dengan menggunakan strategi yang diusulkan untuk mengisi beban kendaraan listrik domestik. Dimana sekelompok kendaraan listrik rumah tangga dimodelkan menggunakan *Monte Carlo Approach* [12]. Setelah itu, metode pengisian kendaraan listrik optimal berbasis pemrograman bilangan bulat 0-1 diusulkan untuk mengontrol berat harian jaringan. Studi ini berusaha untuk memvalidasi efektivitas pendekatan pengisian optimal yang disarankan dan pentingnya mempertimbangkan elemen empat musim saat menjadwalkan beban pengisian kendaraan listrik dengan menggunakan sistem daya

terdistribusi IEEE 33 sebagai contoh. Kesenjangan puncak-lembah jaringan, tingkat fluktuasi tegangan, dan kehilangan transmisi semuanya dapat dikurangi menggunakan metode pemrograman bilangan bulat 0-1 yang diusulkan, menurut hasil simulasi. Selain itu, dengan mempertimbangkan kondisi empat musim memiliki beberapa potensi untuk lebih mengurangi kehilangan gearbox dalam sistem tenaga. Menurut hasil optimasi, celah puncak-lembah dan tingkat fluktuasi tegangan rata-rata dari jaringan yang disediakan dapat meningkat masing-masing sekitar 33% dan 50%, ketika kendaraan listrik terhubung ke jaringan. Tingkat kehilangan transmisi jaringan rata-rata selama setahun juga telah meningkat menjadi 3,65% atau sekitar 13,06% meningkat. Pendekatan pemrograman bilangan bulat 0-1 digunakan untuk mengoptimalkan beban pengisian kendaraan listrik untuk mengurangi celah puncak-lembah, tingkat fluktuasi tegangan, dan tingkat kehilangan transmisi jaringan rata-rata dari jaringan yang disediakan. Jika dibandingkan dengan tidak menghubungkan kendaraan listrik ke jaringan, pendekatan pengisian kendaraan listrik yang diusulkan dapat meminimalkan kesenjangan puncak-lembah jaringan dan tingkat fluktuasi tegangan sekitar 45%. Selain itu, dibandingkan dengan tidak menggunakan pemrograman bilangan bulat 0-1, tingkat kehilangan jaringan rata-rata selama setahun turun menjadi 3,50%, penurunan rata-rata sekitar 4,11%. Selain itu, dengan memperhitungkan elemen musiman, tingkat kehilangan transmisi jaringan dapat diturunkan menjadi 3,45%, dan waktu optimal untuk mengisi daya kendaraan listrik berbeda secara signifikan dari ketika faktor empat musim diabaikan.

Boston dan *Werthmann* menggunakan data dunia nyata dari *Ford* kendaraan listrik untuk menganalisis pengaruh faktor empat musim dan banyak faktor lain seperti harga bahan bakar, harga listrik, infrastruktur pengisian lokal, dan lokasi geografis pada perilaku pengisian daya dan kebiasaan mengemudi. Mereka menyimpulkan bahwa armada *Ford* PHEV dan BEV menunjukkan bahwa panjang perjalanan rata-rata berada dalam kisaran baterai kendaraan, dengan rentang harian BEV berada dalam kisaran baterai dan PHEV memiliki variabilitas yang lebih besar, menunjukkan peningkatan pemanfaatan kendaraan, terutama untuk perjalanan yang lebih lama di musim panas. Menurut warga *California* yang menggunakan kendaraan konvensional, jarak tempuh kendaraan listrik umumnya turun sepanjang musim dingin. Selain itu, di musim panas, pengemudi *Fusion Energi* di Kanada dan *California* masing-masing menempuh jarak 48,6 mil hingga 50,3 mil. Pemilik *California Fusion Energi* dikenakan biaya 7,93 hingga 8,89 sen lebih sedikit per minggu daripada rekan-rekan Kanada mereka. Mengingat perbedaan harga antara bensin dan listrik, pelanggan *California Fusion Energi* cenderung membayar jauh lebih sedikit daripada pelanggan *California*. Di musim dingin, Tidak mengherankan bahwa pemilik *Canadian Fusion Energi* akan dikenakan biaya lebih dari pemilik di *California* mengingat biaya bensin 25% lebih banyak dan biaya energi 1/3 sebanyak di *Montreal* seperti yang terjadi di *San Francisco* ini karena pengaruh faktor musiman, dan banyak faktor lain yang disebutkan sebelumnya.

Ul-Haq et al. mengusulkan beberapa kasus untuk memodelkan beban perumahan yang terkait dengan profil beban pengisian kendaraan listrik. Hasil yang diperoleh, yang didasarkan pada struktur pengisian kendaraan listrik yang bergantung pada aktivitas tipe perjalanan, menunjukkan bagaimana yang terakhir berbeda untuk musim yang berbeda, seperti yang diwakili oleh bulan Maret, Agustus, dan Desember, dan itu juga menggambarkan dampak perubahan pola aktivitas pengguna kendaraan listrik dan faktor lingkungan. Selain itu, tampaknya konsekuensi dari mempertimbangkan skema pengisian kendaraan listrik yang terkontrol dan tidak terkontrol sangat signifikan dalam menentukan pola pengisian. Selanjutnya, pada berbagai tingkat penetrasi kendaraan listrik dari pengisian kendaraan listrik fase tunggal yang tidak merata, faktor ketidakseimbangan tegangan diperiksa dan dihitung. Ketika bagian terakhir didistribusikan di tiga fase yang dijelaskan dalam tiga musim berbeda dengan cara yang ditunjukkan di bawah ini, ketidakseimbangan Tegangan yang tidak memadai ditunjukkan pada EVPL hanya 34%: Fase 'a' dan 'b' masing-masing mendukung 58% beban untuk pengisian kendaraan listrik, tetapi fase 'c' hanya menangani 17% beban. Sementara node tertentu dalam sistem yang diteliti dapat mendukung tingkat penetrasi kendaraan listrik sebesar 40% di bawah skenario pengisian tidak seimbang yang serupa (beban 59%, 25%, dan 16% pada fase a, b, dan c, masing-masing), yang diakui sebagai lebih rentan terhadap indeks ketidakseimbangan tegangan. Akibatnya, penelitian sebelumnya menyimpulkan bahwa musim dapat mempengaruhi kebiasaan mengemudi dan pengisian daya dari permintaan pengisian kendaraan listrik.

Karena peningkatan pesat kendaraan listrik, peramalan beban diperlukan untuk menghindari peningkatan permintaan yang tidak terduga. Pengisian beban penumpang kendaraan listrik telah mempengaruhi model peramalan beban kendaraan listrik. Hari libur dan interval empat musim dijelaskan oleh [Markov Chains](#) [13] dan *Monte Carlo*. Frekuensi pengisian diperhitungkan dalam meramalkan beban pengisian kendaraan listrik dengan menggunakan algoritma *Monte Carlo*. Analisis dilakukan pada metode di mana perubahan daya pengisian antara mode lambat dan cepat. Pertama, mobil pribadi, bus, dan taksi dapat dikategorikan dalam jenis kendaraan listrik. Kedua, tiga jenis frekuensi pengisian dan TIK untuk kendaraan listrik diperiksa, dan [fungsi kerapatan probabilitas](#) [14] terkait dibangun. Ketika algoritma [simulasi Monte Carlo](#) [15] digunakan untuk menentukan hari pengisian beban kendaraan listrik, hasilnya mengungkapkan bahwa waktu pengisian puncak adalah antara jam 9 pagi dan 19 malam. Kondisi iklim sehari-hari memiliki dampak tidak langsung pada jumlah energi yang dibutuhkan untuk mengisi daya kendaraan listrik, oleh karena

itu penelitian di masa depan dapat memperhitungkan hal ini lebih lanjut untuk menghasilkan prediksi yang lebih akurat. Dalam penelitian ini, waktu simulasi *Monte Carlo* ditetapkan setidaknya 5000 kali. Di mana [koefisien varians](#) [16] beban pengisian kurang dari 0,05%. Jika tidak, simulasi gagal menyatu, dan perhitungan harus dimulai ulang. Selain itu, keakuratan hasil yang diperoleh dari *Monte Carlo* tidak menyebutkan.

Dalam studi terbaru, metode peramalan dapat diklasifikasikan berdasarkan teknik seperti teknik klasik, pembelajaran mesin, dan pembelajaran mendalam. Dalam teknik klasik, model peramalan beban tergantung pada asumsi. Namun, jenis teknik ini memiliki kemampuan bahwa faktor tersebut dapat dikumpulkan dan ditafsirkan dari nilai yang diperkirakan. Teknik inferensi regresi, ARIMA, dan Bayesian dapat digunakan dalam studi kendaraan listrik.

Pengisian daya pintar adalah salah satu solusi potensial karena memanipulasi proses pengisian untuk mencapai berbagai tujuan sambil mengandalkan kemampuan beradaptasi dari setiap prosedur pengisian. Memperkirakan jumlah energi yang dibutuhkan dan berapa lama setiap prosedur pengisian akan berlangsung di stasiun pengisian diperlukan agar pengisian daya pintar menjadi efektif. Dalam studi ini, informasi dari catatan perjalanan digunakan untuk menghasilkan proyeksi [kuantil](#) dari waktu yang dihabiskan parkir dan energi yang digunakan, yang kira-kira didasarkan pada jarak perjalanan berikutnya. Persepsi multi-layer diterapkan dengan fungsi tilting loss, alat estimasi kepadatan kernel probabilitas multivariat, dan regresi kuantil untuk tujuan ini. Dibandingkan dengan data yang diperoleh di stasiun pengisian, pemeriksaan di luar sampel mengungkapkan bahwa memasukkan detail lokal dari catatan perjalanan kendaraan meningkatkan [akurasi perkiraan](#) sebesar 13,7% untuk durasi parkir dan 0,56% untuk jarak perjalanan. Selain itu, dibandingkan dengan prediksi titik, analisis studi kasus menunjukkan bahwa menggunakan prakiraan probabilitas dapat mengontrol gangguan operasi pengisian daya secara lebih efektif. Hingga 7,0% lebih sedikit gangguan yang dihasilkan menggunakan perkiraan probabilitas, yang dapat membatasi permintaan pengemudi untuk mobilitas. Temuan ini menunjukkan nilai memanfaatkan kebiasaan mengemudi kendaraan listrik oleh operator stasiun pengisian. Pengisian daya pintar dan penggunaan model yang disarankan sebagai standar untuk kegiatan peramalan terkait sehingga meningkatkan situasi bagi mereka yang beroperasi. Dalam hal MAPE, dan [RMSE](#), kesalahan peramalan untuk waktu parkir dan jarak tempuh tidak terlalu sederhana atau besar. Untuk tujuan perbandingan, penelitian ini tidak dapat menemukan evaluasi yang sebanding antara teknik yang diusulkan dan teknik lain untuk memvalidasi akurasi dan efisiensi hasil.

Teknik prediksi yang kuat dan akurat ditawarkan dengan menggunakan [algoritma pembelajaran mesin](#). Seperti teknik mesin vektor dukungan (SVM) yang dieksplorasi dalam model peramalan. Di mana aplikasi khas dari karakteristik beban pengisian kendaraan listrik menyinggung masalah yang disebabkan oleh waktu pengisian kendaraan listrik (*electric vehicle*) dan ketidakpastian status pengisian (SOC). Model peramalan beban pengisian daya berdasarkan beban masa lalu ditawarkan sebagai solusi untuk masalah akurasi rendah dari metode perkiraan. Model yang disarankan mempertimbangkan berbagai variabel yang mungkin berdampak pada beban, seperti data beban pengisian historis, jumlah kendaraan listrik, jumlah stasiun pengisian yang beroperasi secara teratur, data cuaca, properti minggu, properti liburan, dan informasi lainnya. Contoh numerik dari stasiun pengisian dan *switching* kendaraan listrik digunakan untuk memverifikasi efektivitas dan validitasnya. Dibandingkan dengan peramalan beban pengisian konvensional di bawah karakteristik mengemudi kendaraan listrik, hasilnya menunjukkan penurunan *Mean Absolute Error* (MAE) dan [Root Mean Squared](#) (RMSE) masing-masing sebesar 69,95% dan 64,56%. Namun, penelitian ini tidak membandingkan hasil yang diperoleh dari SVM dengan algoritma lain untuk memvalidasi akurasi dan efisiensi teknik yang diusulkan [7].

Selanjutnya, pendekatan pembelajaran mendalam telah diusulkan seperti jaringan syaraf tiruan (ANN), jaringan syaraf konvolusional (CNN), *Recurrent Neural Network* (RNN), *Long Short-Term Memory* (LSTM), dan *Gated Recurrent Unit* (GRU). Sedangkan tujuan utama penelitian adalah untuk mengembangkan model peramalan yang secara akurat memperkirakan beban listrik berdasarkan pengamatan beban listrik perusahaan listrik saat ini. Nilai model peramalan adalah dalam mengantisipasi beban listrik di masa depan, yang akan membantu perusahaan listrik mendistribusikan beban listrik mereka dengan lebih baik sambil menghemat uang dan sumber daya. Untuk memprediksi tuntutan listrik, tiga algoritma pembelajaran mendalam digunakan: (1) *Long Short-Term Memory* (LSTM), (2) *Gated Recurrent Units* (GRU), dan (3) *Recurrent Neural Networks* (RNN). Dalam pengujian menggunakan model, model GRU menunjukkan akurasi tertinggi dan kesalahan terendah. Nilai R-kuadrat untuk model GRU adalah 90,228%, dan nilai [Mean Squared Error](#) (MSE) dan *Mean Absolute Error* (MAE) masing-masing adalah 0,00215% dan 0,03266%, menurut hasil [7]. Namun, penelitian ini tidak mempertimbangkan perilaku konsumen dalam konsumsi listrik di musim yang berbeda. Selain itu, parameter dari ketiga algoritma tidak disetel untuk mendapatkan hasil yang lebih akurat dan efisien dengan mengurangi kelompok kesalahan dan meningkatkan nilai R-kuadrat.

Karena non-linearitas model peramalan, kombinasi jaringan syaraf tiruan dan sistem inferensi *fuzzy* (FIS) digunakan dalam populer. Sedangkan tujuan utama penelitian ini adalah untuk membangun model peramalan berdasarkan empat variabel utama suhu udara, kecepatan angin, kepadatan udara, dan tekanan udara yang memiliki dampak signifikan pada daya keluaran [ladang angin](#). Akurasi prediksi model yang disarankan akan ditingkatkan dengan memperhitungkan semua variabel ini. Aturan *fuzzy* dan jaringan adaptif digunakan dalam konstruksi dan pengujian model prediksi yang disarankan. Empat subset data, masing-masing dibagi menjadi empat musim dalam setahun, digunakan untuk mengevaluasi model prediksi. Akurasi prediksi model yang diusulkan ditingkatkan dengan memperhitungkan semua variabel yang disebutkan sebelumnya. Dengan menghitung [Root Mean Squared Error](#) (RMSE) dan persentase *Real Error* (ReErr) untuk empat subset, kebenarannya diperiksa dan dikonfirmasi. Rata-rata RMSE dan ReErr masing-masing adalah 0,003743% dan 5,86% . Penelitian ini tidak hanya tidak menyempurnakan parameter sistem inferensi *fuzzy*, tetapi juga tidak menggunakan teknik yang berbeda untuk memvalidasi keakuratan hasil yang diperoleh dan tidak mengevaluasi efisiensi teknik yang diusulkan.

Karena itu, data nyata tentang volume beban pengisian kendaraan listrik langka. Sebagian besar studi simulasi biasanya tergantung pada jumlah dan peristiwa pengisian kendaraan listrik yang ditentukan oleh jenis hari seperti hari kerja, hari libur, atau akhir pekan, penggunaan energi karena menggunakan AC dan pemanas memiliki pengaruh besar pada drainase baterai dan status pengisian (SOC), jenis kendaraan listrik dan data lalu lintas jalan. Jadi cuaca, suhu, atau data empat musim *approach* telah diusulkan dalam studi terbaru.

Akibatnya, keterbatasan studi yang disebutkan sebelumnya dapat dicantumkan sebagai berikut:

1. Sebagian besar penelitian tidak mempertimbangkan dalam model peramalan suhu dan kondisi musiman, di mana pengisian dan pengurusan baterai kendaraan listrik dipengaruhi oleh penggunaan kendaraan listrik oleh pemilik.
2. Peramalan profil beban kendaraan listrik didasarkan pada data empiris karena kelangkaan data nyata.
3. Sebagian besar penelitian mengevaluasi studi mereka dengan hanya menggunakan satu teknik. Di mana parameter teknik yang diusulkan tidak disetel untuk mendapatkan hasil perkiraan yang paling akurat dan efisien.

Dalam makalah ini, kumpulan data nyata untuk beban pengisian kendaraan listrik diterapkan dalam studi numerik. Empat pendekatan mesin dan pembelajaran mendalam sebelumnya diadopsi untuk memprediksi beban pengisian kendaraan listrik yang dipengaruhi oleh faktor musiman. Kontribusi dari pekerjaan ini dapat didaftar sebagai berikut:

1. Dataset nyata konsumsi kendaraan listrik di *Spain* dianalisis dan diproses sebelumnya dalam empat musim (musim dingin, musim semi, musim panas, dan musim gugur) sehingga pengaruh empat musim (suhu dan sifat konsumsi pemilik kendaraan listrik yang berpengaruh pada pengisian dan drainase baterai kendaraan listrik) pada profil beban pengisian kendaraan listrik dapat dipelajari dalam kerangka peramalan beban.
2. Empat algoritma mesin (*Machine Algorithm*) dan *Deep Learning* unggulan (ANN, LSTM, GRU, dan ANFIS) dipilih untuk melatih, menguji, dan memperkirakan profil beban pengisian kendaraan listrik.
3. Kelompok kesalahan (MAE, RMSE, dan MAPE) dihitung untuk memeriksa empat teknik yang diusulkan dalam model peramalan beban.
4. Keakuratan model ditentukan oleh koefisien korelasi R .

Makalah ini dibagi menjadi tujuh bagian. Bagian dua secara singkat menunjukkan empat pendekatan mesin dan pembelajaran mendalam. Bagian tiga menjelaskan kumpulan data dari beban pengisian kendaraan listrik di *Spain* dan kemudian menunjukkan pra-pemrosesan data. Bagian empat mengusulkan kerangka kerja peramalan beban. Bagian lima menunjukkan data sistem yang diteliti dan menyesuaikan parameter masing-masing algoritma. Hasil simulasi yang diperoleh dari empat pendekatan unggulan untuk empat skenario telah disajikan pada bagian enam. Pembahasan poin-poin utama dirangkum, diikuti oleh bagian tujuh yang menggambarkan kesimpulan makalah.

2. METODE

2.1. Objek Penelitian

Penelitian dilakukan di benua Eropa, tepatnya negara Spanyol. Penelitian ini difokuskan pada masalah penyediaan dataset realistis profil beban kendaraan listrik untuk mengatasi potensi peningkatan penetrasi kendaraan listrik dengan mempertimbangkan efek musim yang terjadi dan dampak lingkungan serta upaya pengurangan emisi pengisian kendaraan listrik terhadap pencemaran CO₂ di negara Spanyol.

2.2. Tahap Persiapan

2.2.1. Identifikasi dan Perumusan Masalah

Pada tahap ini peneliti menentukan topik penelitian serta masalah yang akan diangkat dan diteliti berdasarkan kondisi yang ada di negara *Spanyol*, yaitu mengidentifikasi pencemaran gas CO₂. Kemudian merumuskan masalah mengenai pengaruh pengisian harian mobil listrik berdasarkan beberapa musim yaitu musim dingin, musim semi, musim panas, dan musim gugur.

2.2.2. Penentuan Tujuan Penelitian

Pada tahap ini ditentukan tujuan atau arah dari penelitian yang dilakukan sehubungan dengan permasalahan yang telah diangkat, yaitu untuk mengetahui seberapa besar *Mean Squared Error* (MSE), *Root Squared Error* (RMSE), *Mean Absolute Percentage Error* (MAPE) dan *Mean Absolute Error* (MAE) yang dihasilkan dari dataset penelitian.

2.3. Metode Pengumpulan Data

Adapun data yang digunakan pada penelitian adalah data primer yang diperoleh dari pengamatan secara langsung yang dilakukan oleh peneliti.

Pengumpulan data dilakukan dengan beberapa metode yaitu:

a. Observasi

Metode observasi adalah metode pengumpulan data yang dilakukan dengan melihat dan mengadakan pengamatan secara langsung terhadap transmisi dan distribusi pengisian mobil listrik. Observasi dilakukan secara mendalam untuk mengetahui secara rinci keadaan lingkungan negara *Spanyol*.

b. Wawancara

Wawancara merupakan metode pengumpulan data yang dilakukan dengan tanya jawab secara langsung kepada bagian pihak pengguna kendaraan listrik (*electric vehicle*) dan stasiun pengisian bahan bakar serta pihak lainnya di negara *Spanyol*. Wawancara dilakukan dengan memberikan pertanyaan terhadap segala permasalahan-permasalahan yang dialami dan sejauh mana solusi pemecahan yang telah dilakukan oleh pihak pemerintah negara *Spanyol*.

c. Studi Pustaka

Studi pustaka adalah salah satu metode yang dilakukan dengan cara mengambil bahan-bahan dari kajian literatur untuk mendapatkan informasi yang mendukung dengan permasalahan yang dibahas. Dari studi pustaka ini, peneliti memperoleh data apa saja yang diperlukan dalam penelitian yang dilakukan.

d. Dokumentasi

Dokumentasi dilakukan untuk mengambil gambar lingkungan kerja yang mendukung kinerja pemerintah dalam memenuhi pelayanan terhadap masyarakat.

2.4. Cara Pengambilan Data

Penelitian dilakukan di negara *Spanyol*. Subjek penelitian adalah untuk mengetahui sekelompok kesalahan yang digunakan seperti *Root Mean Square Error* (RMSE), *Mean Absolute Error* (MAE) dan *Mean Absolute Percentage Error* (MAPE) untuk mengevaluasi efektivitas algoritma yang diusulkan.

Langkah-langkah dalam melakukan pengamatan penelitian adalah sebagai berikut:

1. Berkomunikasi secara langsung dengan petugas-petugas pengisian mobil listrik di wilayah tertentu dengan masalah yang dikaji dengan melakukan wawancara.
2. Dalam melakukan penelitian mengambil semua wilayah kerja pengisian mobil listrik.
3. Aktivitas pencarian data dimulai dengan melakukan pengamatan wilayah.

2.5. Analisa Data

Analisa data merupakan perhitungan secara kuantitatif dengan menggunakan rumusan yang telah ditentukan sebagai penganalisa data yang sesuai dengan masalah yang ada.

2.5.1. Metode *Recurrent Neural Network* (RNN)

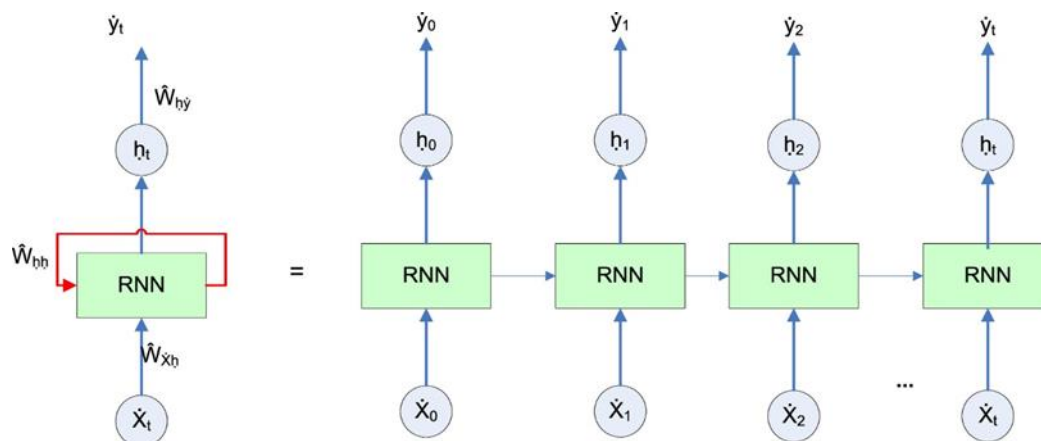
Recurrent Neural Network (RNN) adalah jenis arsitektur jaringan syaraf tiruan yang dirancang khusus untuk mengatasi masalah sekuensial dan temporal. Keunggulan utama RNN adalah kemampuannya untuk memproses dan memahami data sekuensial, di mana informasi dari waktu sebelumnya dapat mempengaruhi pemrosesan informasi pada waktu berikutnya. Hal ini menjadikan RNN sangat berguna dalam berbagai aplikasi, seperti pengenalan suara, pemodelan bahasa, dan prediksi deret waktu.

Rumus yang digunakan yaitu:

$$h_t = f(\hat{W}_{xh} \cdot x_t + \hat{W}_{hh} \cdot h_{t-1}) \quad (2.5.1)$$

$$y_t = g(\hat{W}_{hy} \cdot h_t)$$

(2.5.2)



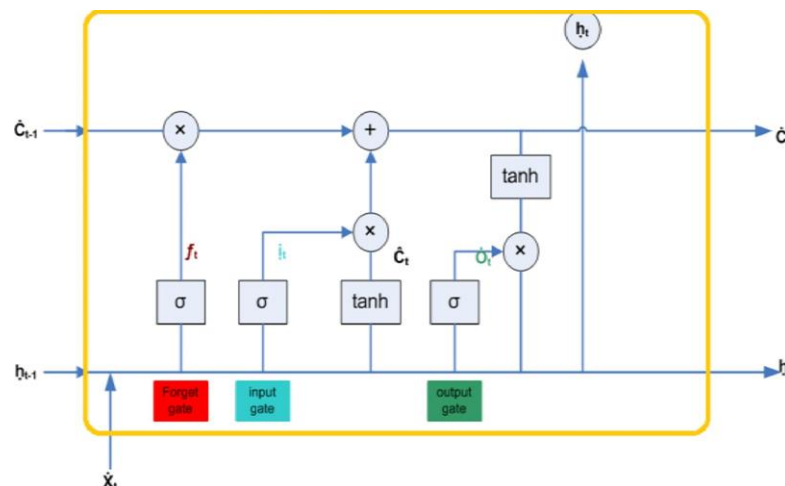
Gambar 2.1. Struktur Sederhana RNN

Tabel 2.1. Parameter RNN

x_t, y_t	Status input dan status <i>output</i> dalam struktur RNN pada waktu t
h_t	Status tersembunyi pada waktu t dalam algoritma RNN
$\hat{W}_{xh}, \hat{W}_{hh}, \hat{W}_{hy}$	Berbagi matriks bobot untuk status input saat ini x_t dalam algoritma RNN
h_{t-1}	<i>Output</i> dari <i>hidden layer</i> pada waktu sebelumnya
$f(\cdot), g(\cdot)$	Fungsi aktivasi yang digunakan dalam RNN
x_0	Input awal diambil oleh RNN
h_0	Keadaan <i>hidden layer</i> dalam struktur RNN
y_0	<i>Output</i> yang dihasilkan dalam struktur RNN
h_0, x_1	Input untuk langkah selanjutnya dalam struktur RNN

2.5.2. Metode Long Short-Term Memory (LSTM)

Long Short-Term Memory (LSTM) adalah varian dari arsitektur jaringan syaraf rekuren (RNN) yang dirancang khusus untuk mengatasi masalah *vanishing gradient* dan *exploding gradient* yang sering terjadi pada RNN tradisional. LSTM diperkenalkan oleh Sepp Hochreiter dan Jürgen Schmidhuber pada tahun 1997.



Gambar 2.2. Struktur dasar LSTM

LSTM memiliki struktur yang lebih kompleks dan mengintegrasikan mekanisme pintar penyimpanan dan pengambilan informasi, sehingga lebih efektif dalam memodelkan dan menjaga hubungan temporal yang kompleks dalam data sekuensial. Beberapa komponen kunci dari LSTM meliputi:

1. *Cell state* (C_t):

Ini adalah saluran informasi utama yang diangkut melalui seluruh sekuensi. LSTM dirancang untuk mempertahankan dan mengalirkan informasi melalui *cell state*, sehingga dapat mengatasi masalah *vanishing gradient*.

2. *Forget Gate*:

Forget gate (f_t) menentukan sejauh mana informasi lama harus dilupakan dari *cell state*. Ini membantu dalam mengelola memori jangka panjang.

3. *Input Gate*:

Input gate (i_t) menentukan sejauh mana informasi baru harus dimasukkan ke dalam *cell state*. Ini melibatkan dua bagian: pertama, menentukan sejauh mana nilai potensial yang baru, dan kedua, memutuskan nilai yang sebenarnya yang akan ditambahkan ke dalam *cell state*.

4. *Cell state Update*:

Cell state diperbarui (C_t) berdasarkan hasil dari *forget gate* dan *input gate*.

5. *Output Gate*:

Output gate (o_t) menentukan sejauh mana *cell state* harus mempengaruhi *output* dari LSTM.

Langkah-langkah ini memungkinkan LSTM untuk memilih informasi yang akan disimpan atau dilupakan pada setiap langkah waktu, sehingga lebih efektif dalam memahami dan mengingat pola jangka panjang dalam data sekuensial.

Secara matematis, langkah-langkah LSTM dapat dijelaskan sebagai berikut:

$$f_t = \sigma(\hat{W}_f \cdot [h_{t-1}, x_t] + b_f) \quad (2.5.3)$$

$$i_t = \sigma(\hat{W}_i \cdot [h_{t-1}, x_t] + b_i) \quad (2.5.4)$$

$$\tilde{C}_t = \tanh(\hat{W}_C \cdot [h_{t-1}, x_t] + b_C) \quad (2.5.5)$$

$$C_t = f_t \cdot C_{t-1} + i_t \cdot \tilde{C}_t \quad (2.5.6)$$

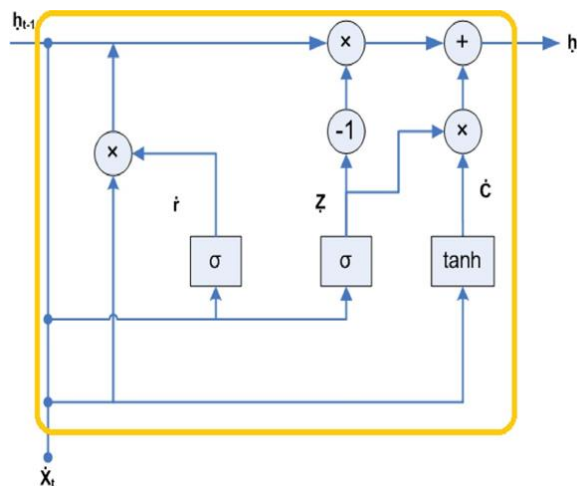
$$o_t = \sigma(\hat{W}_o \cdot [h_{t-1}, x_t] + b_o) \quad (2.5.7)$$

$$h_t = o_t \cdot \tanh(C_t) \quad (2.5.8)$$

Di sini, σ adalah fungsi sigmoid, \tanh adalah fungsi tangen hiperbolik, \hat{W}_f , \hat{W}_i , \hat{W}_C , W_o adalah matriks bobot, dan b_f , b_i , b_C , b_o adalah vektor bias $[h_{t-1}, x_t]$ adalah penggabungan dari *output* pada waktu sebelumnya (h_{t-1}) dan input saat ini (x_t).

2.5.3. Metode Gated Recurrent Unit (GRU)

Gated Recurrent Unit (GRU) adalah varian dari arsitektur *Recurrent Neural Network* (RNN) yang dikembangkan untuk mengatasi beberapa masalah yang dimiliki oleh RNN konvensional, terutama terkait dengan masalah *vanishing gradient* dan *exploding gradient*. GRU mempertahankan kemampuan untuk mengatasi hubungan temporal dalam data sekuensial, seperti teks atau deret waktu, namun dengan arsitektur yang sedikit lebih sederhana dibandingkan dengan *Long Short-Term Memory* (LSTM).



Gambar 2.3. Struktur sel GRU

Berikut adalah beberapa komponen kunci dari GRU:

1. *Update Gate* (z_t):

Ini mengontrol sejauh mana informasi baru harus diintegrasikan ke dalam unit memori.

$$\text{Rumusnya adalah } z_t = \sigma(\hat{W}_z \cdot [h_{t-1}, x_t]), \quad (2.5.9)$$

di mana σ adalah fungsi sigmoid.

2. *Reset Gate* (r_t):

Ini menentukan sejauh mana untuk melupakan informasi dari masa lalu.

Rumusnya adalah $r_t = \sigma(\hat{W}_r \cdot [h_{t-1}, x_t])$,

(2.5.10)

di mana σ adalah fungsi sigmoid.

3. *Candidate Hidden state* (\tilde{h}_t):

Ini adalah kandidat untuk *hidden state* baru yang dihitung berdasarkan input saat ini dan *hidden state* sebelumnya.

Rumusnya adalah $\tilde{h}_t = \tanh(\hat{W}_h \cdot [r_t \cdot h_{t-1}, x_t])$,

(2.5.11)

di mana \tanh adalah fungsi tangen hiperbolik.

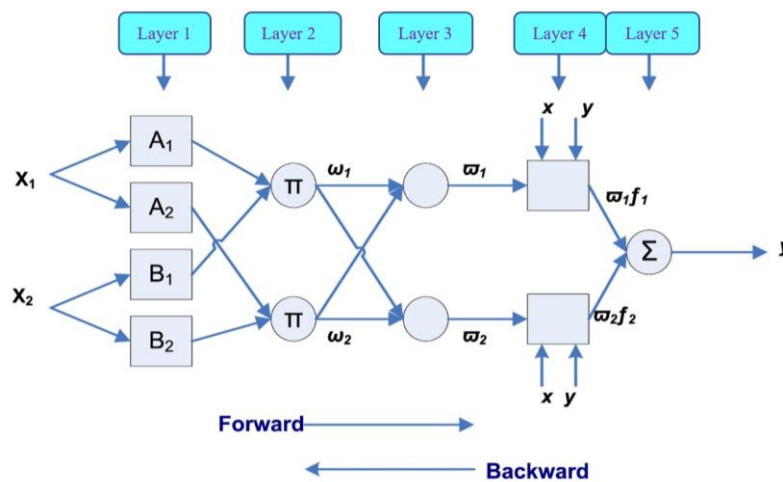
4. *Hidden state* (h_t):

Ini adalah *output* aktual dari GRU pada waktu t .

Rumusnya adalah $h_t = (1 - z_t) \cdot h_{t-1} + z_t \cdot \tilde{h}_t$.

(2.5.12)

GRU memungkinkan model untuk memutuskan sejauh mana informasi lama harus dipertahankan dan sejauh mana informasi baru harus diintegrasikan. Dengan menggunakan *gate-gate* ini, GRU dapat mengatasi masalah *vanishing gradient* dan *exploding gradient* yang sering terjadi pada RNN tradisional, memungkinkan pembelajaran yang lebih efektif dari pola temporal dalam data sekuensial. Meskipun GRU memiliki struktur yang lebih sederhana daripada LSTM, keduanya sering digunakan dalam tugas pemodelan sekuensial yang kompleks.



Gambar 2.4. Struktur ANFIS

Adaptive Neural Fuzzy Inference System (ANFIS) adalah suatu metode yang menggabungkan teknik-teknik jaringan syaraf tiruan (*neural network*) dan sistem inferensi *fuzzy* untuk memodelkan hubungan kompleks antara variabel-variabel input dan *output*. ANFIS dikembangkan oleh Jang pada tahun 1993 dan telah banyak digunakan dalam berbagai bidang, termasuk kontrol sistem, prediksi, dan pengambilan keputusan.

ANFIS menggunakan aturan *fuzzy* dan pembelajaran jaringan syaraf untuk menghasilkan model yang adaptif dan dapat belajar dari data. Secara umum, proses pembelajaran ANFIS terdiri dari beberapa tahap:

1. Fase 1 - Pembentukan Aturan *Fuzzy*:

- Input data diterapkan ke beberapa fungsi keanggotaan *fuzzy* yang ditentukan sebelumnya untuk setiap variabel input.
- Setiap fungsi keanggotaan *fuzzy* memberikan kontribusi pada suatu aturan *fuzzy*.
- Nilai derajat keanggotaan (*membership degree*) dihitung berdasarkan sejauh mana input data cocok dengan masing-masing fungsi keanggotaan.

2. Fase 2 - Pembentukan Struktur Jaringan Syaraf:

- Neuron di layer input representatif untuk setiap aturan *fuzzy* dan memiliki *output* yang dihitung sebagai hasil perkalian derajat keanggotaan dengan nilai input.
- Layer *output* merupakan hasil penjumlahan dari *output* masing-masing neuron di layer input.

3. Fase 3 - Pelatihan Jaringan:

- Bobot dan parameter lainnya di jaringan syaraf disesuaikan menggunakan metode pembelajaran tertentu (misalnya, metode penurunan gradien atau algoritma evolusi) untuk meminimalkan kesalahan antara *output* sebenarnya dan *output* yang diprediksi oleh jaringan.

ANFIS memanfaatkan kelebihan sistem inferensi *fuzzy* dalam menangani ketidakpastian dan ketidaktepatan, sementara pada saat yang sama menggunakan kemampuan jaringan syaraf untuk belajar dari

data dan menangani hubungan yang kompleks. Kelebihan ANFIS meliputi kemampuannya untuk menggambarkan hubungan nonlinier dan mampu beradaptasi dengan perubahan dalam data input.

2.6. Proses Pencilan

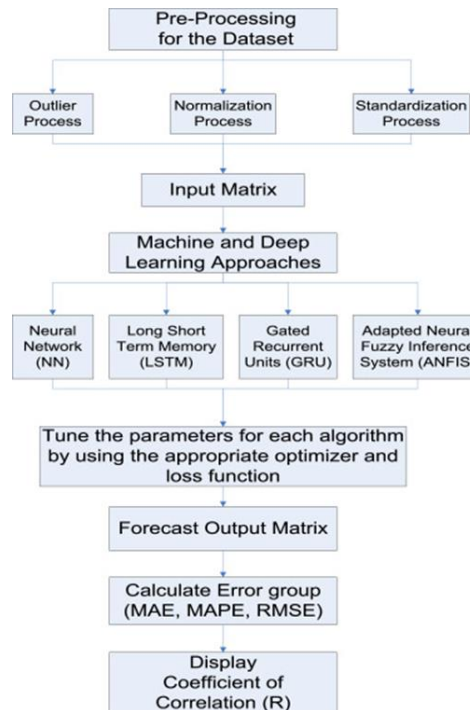
Untuk menghindari faktor interferensi atau data yang hilang dalam dataset yang menyebabkan kesalahan, beberapa teknik digunakan dalam proses ini. Untuk kasus nol data yang ada, itu dikonversi ke nol untuk jenis data tertentu. Kemudian data ini dihapus.

2.7. Proses Normalisasi dan Standardisasi

Proses normalisasi data dilakukan untuk mengatribusikan nilai penskalaan. Proses ini akan membuat nilai numerik terletak dalam interval yang sama. Data yang dinormalisasi dalam *Machine Learning* akan membuat model peramalan beban lebih efisien. Tiga teknik yang digunakan untuk menormalkan data seperti data yang dinormalisasi dengan penskalaan desimal, data yang dinormalisasi dengan metode *Min-Max*, dan proses yang dinormalisasi dengan metode *Z-score*.

Ketiga teknik tersebut memiliki operasi yang sama pada data. Untuk penelitian ini, data dinormalisasi dengan skala desimal. Nilai data dalam penelitian ini akan berada pada kisaran $[0, 1]$. Data yang dinormalisasi memiliki standar antara rata-rata dan standar deviasi agar lebih cocok. Untuk mencegah divergen himpunan data pelatihan, data pelatihan distandarisasi dilakukan dengan mengurangi rata-rata nilai data dan membaginya dengan standar deviasi.

2.8. Kerangka Pemecahan Masalah



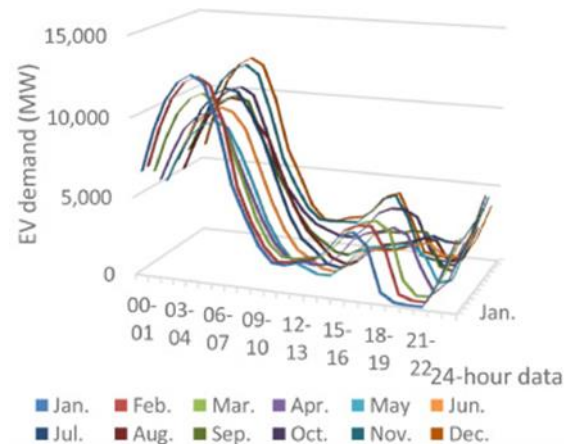
Gambar 2.5. Kerangka kerja peramalan berdasarkan pendekatan mesin dan pembelajaran mendalam.

3. HASIL DAN PEMBAHASAN

Di bagian ini, pelatihan dan dataset pengujian telah diproses sebelumnya dan dimasukkan ke dalam empat algoritma mesin dan pembelajaran mendalam yang diusulkan untuk mengevaluasi kinerja dan membandingkan hasil yang diperoleh. Dataset pengisian mobil listrik (*electric vehicle*) telah dilatih dan diperkirakan dengan menggunakan RAM 24.00 GB versi MATLAB 2021a, CPU 12th Gen Intel® Core™ i9-12900KF 3.19 GHz.


3.1. Pra-Pemrosesan Data

Pra-pemrosesan data dilakukan pertama kali pada dataset dalam tiga tahap proses outlier, normalisasi, dan standardisasi. Matriks input siap ditangani dengan mesin dan algoritma pembelajaran mendalam (*Deep Learning*) dalam kerangka perkiraan. Fungsi kerugian dan pengoptimal dalam mesin dan algoritma *Deep Learning* sangat penting dalam proses pelatihan.



Gambar 3.1. Pengisian harian rata-rata per jam mobil listrik (*electric vehicle*) per bulan (MW).

Gambar 3.1. Menampilkan model peramalan sebelum melakukan pra-pemrosesan data pada model peramalan yang didasarkan pada himpunan data nyata di *Spanyol*. Data tersebut adalah biaya harian rata-rata per jam mobil listrik per bulan dalam Megawatt.



Gambar 3.2. Himpunan data pengisian mobil listrik (*electric vehicle*) harian rata-rata per jam per bulan setelah pra-pemrosesan data.

Gambar 3.2. Menampilkan model *forecasting* setelah melakukan pra-pemrosesan data melalui tiga tahapan yaitu proses *outlier*, normalisasi, dan standardisasi.

Pengoptimalan adalah metode matematika yang diterapkan untuk mengubah atribut jaringan syaraf dan algoritma lain seperti bobot, bias, dan tingkat pembelajaran untuk mengurangi kerugian. Oleh karena itu, fungsi pengoptimal dan kerugian yang sesuai dipilih dengan menyetel parameter untuk setiap algoritma untuk meminimalkan kesalahan antara data yang diprediksi dan himpunan data pelatihan. Ada beberapa pengoptimalan seperti *Stochastic Gradient Descent* (SGD), *Mini Batch Stochastic Gradient Descent* (MB-SGD), *Nesterov Accelerated Gradient* (NAG), *Adaptive Gradient* (AdaGrad), *Root Mean Squared Propagation* (RMSProp), *Adaptive Delta* (Adadelata), *Adaptive Moment Estimation* (Adam), *Algoritma Levenberg-Marquardt* (LMA). Dalam penelitian ini, kami memilih antara pengoptimal yang terdaftar

sebelumnya dan fungsi kerugian seperti *Sum Squared Error* (SSE) dan *Mean Squared Error* (MSE) sesuai dengan masing-masing algoritma yang diusulkan yang diilustrasikan pada tabel 3.1.

Tabel 3.1. Pengoptimalan yang dipilih dan fungsi kerugian sesuai dengan masing-masing algoritma.

Algoritma yang diusulkan	(ANN)	(LSTM)	(GRU)	(ANFIS)
Pengoptimalan yang dipilih	LMA	Adam	Adam	Adam
Fungsi Kerugian	SSE	MSE	MSE	MSE

Dimana SSE dan MSE dapat dihitung dengan rumus:

$$SSE = \sum_{t=1}^N (y_t - \hat{y}_t)^2 \quad (3.1.1)$$

$$MSE = \frac{SSE}{N} \quad (3.1.2)$$

Di mana jumlah sampel ditentukan oleh N , \hat{y} dan y yang merupakan nilai perkiraan dan nilai aktual beban masing-masing.

Untuk pengoptimal, ditemukan bahwa Adam adalah pengoptimal terbaik dan tercepat untuk menyatu dengan minima [7]. Algoritma *Levenberg-Marquardt* direkomendasikan untuk digunakan dengan jumlah kesalahan kuadrat yang membuat pelatihan dengan jaringan syaraf menjadi cepat untuk kesalahan semacam ini [7].

Untuk menentukan efisiensi metode peramalan beban, kami menggunakan dalam penelitian ini koefisien korelasi R . Koefisien korelasi R adalah perhitungan statistik yang menghitung hubungan antara nilai prediksi dan nilai aktual yang diperoleh dalam studi statistik. Koefisien korelasi R menunjukkan ketepatan dan efisiensi antara nilai prediksi dan nilai aktual. Ketika koefisien korelasi R adalah r ke 1, itu berarti bahwa hubungan antara nilai prediksi dan nilai aktual kuat. Koefisien korelasi akan dihitung dengan:

$$R = \frac{\sum (x_i - \bar{x})(y_i - \bar{y})}{\sqrt{\sum (x_i - \bar{x})^2 \sum (y_i - \bar{y})^2}} \quad (3.1.3)$$

3.2. Data Sistem yang Diteliti dan Parameter Algoritma yang Diusulkan

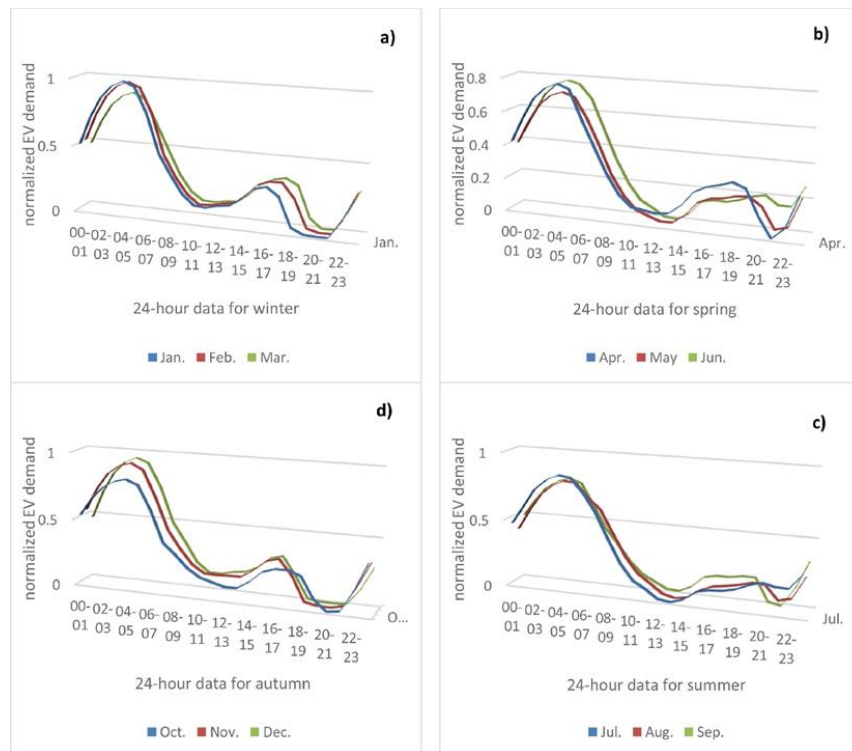
Pada bagian berikut menjelaskan sifat himpunan data, dan cara pengumpulannya. Data yang dipilih perlu ditangani dengan membenarkan parameter masing-masing algoritma untuk mendapatkan akurasi yang lebih baik dalam prediksi dengan lebih sedikit kesalahan.

3.2.1. Data Set yang Diteliti

Data diperoleh dari studi penelitian: 'Kendaraan listrik di Spanyol: Gambaran umum sistem pengisian' dan 'Analisis stasiun pengisian untuk kendaraan listrik di Spanyol' [7]. Data dihitung dari data yang diperoleh dari jaringan listrik Spanyol selama tiga belas tahun dari 2007 hingga 2019. Berdasarkan data yang dirujuk, dataset konsumsi rata-rata kendaraan listrik disediakan. Dataset permintaan pengisian harian rata-rata per jam per bulan kendaraan listrik adalah dari 2007 hingga 2019 yang diperkirakan dalam megawatt.

Himpunan data ini mewakili nilai listrik terendah kendaraan listrik di setiap jam per hari selama 12 bulan selama tiga belas tahun antara 2007 dan 2019 [7]. Di mana permintaan pengisian harian rata-rata kendaraan listrik di setiap jam dalam sehari per bulan di (MW) dapat ditampilkan pada gambar 4.1.

Pada gambar 9 menampilkan permintaan pengisian rata-rata mobil listrik (*electric vehicle*) per jam dalam sehari per bulan setelah melakukan pra-pemrosesan data. Data yang dinormalisasi dibagi untuk empat musim yaitu musim dingin, musim semi, musim panas, dan musim gugur. Dalam studi ini, kami menganggap dataset dibagi menjadi empat musim (musim dingin, musim semi, musim panas, dan musim gugur) pada tahun 2017 dan kisaran suhu di setiap musim dipertimbangkan dalam analisis sebagai faktor empat musim misalnya: di musim dingin, suhu telah berfluktuasi antara 10/30 dan 16/6 dalam derajat *Celcius* sebagai suhu maksimum dan minimum rata-rata. Pada musim semi, kisaran suhu telah berfluktuasi antara 18/8 dan 28/16 °*Celcius* sebagai suhu maksimum dan minimum rata-rata. Di musim panas, suhu berfluktuasi antara 32/19 dan 26/15 °C sebagai suhu maksimum dan minimum rata-rata. Pada musim gugur, suhu telah berfluktuasi antara 19/11 dan 10/4 °C sebagai suhu maksimum dan minimum rata-rata. Jadi, mempertimbangkan suhu sebagai efek empat musim pada konsumsi muatan dan drainase baterai di profil beban mobil listrik.



Gambar 3.3. Himpunan data pengisian harian rata-rata per jam kendaraan listrik per bulan setelah pra-pemrosesan data selama empat musim (musim dingin, musim semi, musim panas, dan musim gugur).

3.2.2. Evaluasi Model yang Diusulkan

Rasio data set dipilih menjadi 0,9/0,1 yang merupakan rasio antara data pelatihan dan data pengujian. Dataset disimulasikan dalam empat musim selama empat bulan yaitu Januari untuk musim dingin, April untuk musim semi, Juli untuk musim panas, dan Oktober untuk musim gugur. Hasilnya diperoleh dari empat algoritma unggulan yang diusulkan yaitu ANN, LSTM, GRU, dan ANFIS.

a. Model yang Dievaluasi dari Algoritma Jaringan Syaraf Tiruan (*Neural Network*)

Jaringan default tiga lapisan telah diinisialisasi dengan sepuluh neuron. Dimana ketiga layer tersebut adalah layer input, layer tersembunyi, dan layer *output*. [Jaringan syaraf terdiri](#) dari node dan setiap node terdiri dari satu set input, bobot, dan nilai bias. Data input ditransfer dalam lapisan tersembunyi jaringan melalui input dan berat lapisan. *Output* yang memadai diperoleh dengan menggunakan berat dan bias dalam jaringan syaraf yang membedakan neuron. Baik bobot maupun bias diperlukan untuk mengajarkan model dan mendapatkan *output* yang akurat [7].

Kesalahan jumlah kuadrat (SSE) digunakan sebagai metrik kinerja. Kemudian, algoritma default *Levenberg-Marquardt* (LMA) digunakan untuk melatih dataset. Untuk meningkatkan efisiensi, jaringan akan dimuat setelah jaringan dilatih sebelumnya kecuali jaringan pelatihan ulang tiba-tiba diberlakukan. Di mana parameter penyetelan untuk ANN dipilih seperti yang ditunjukkan pada [Tabel 3.2](#). "*numlayers*" mewakili beberapa lapisan. "IW, LW, B" adalah bobot input, bobot lapisan, dan bias masing-masing di mana nilainya dalam bentuk matriks 2 kali 1.

b. Model yang Dievaluasi dari Algoritma *Long Short-Term Memory* (LSTM) dan Algoritma *Recurrent Unit* (GRU).

Tabel 3.2. Parameter penyetelan untuk algoritma ANN.

Jumlah lapis (<i>numlayer</i>)	Berat input (<i>iw</i>)	Berat Lapisan (<i>LW</i>)	Bias (<i>b</i>)
3	[2, 1]	[2, 2]	[2, 1]

Jaringan regresi LSTM dan GRU dibuat. Dimana jumlah node atau unit tersembunyi di kedua algoritma tersebut adalah 200. *Mean Square Error* (MSE) digunakan sebagai metrik kinerja. Kemudian, *Adaptive moment estimation* (Adam) digunakan untuk melatih himpunan data. Di mana parameter tuning untuk LSTM dan GRU dipilih seperti yang ditunjukkan pada [Tabel 3.3](#). Di mana jumlah fitur dan respons menggambarkan dua input dan satu *output*. Jumlah *epochs* menggambarkan jumlah iterasi lengkap dari himpunan data yang akan dijalankan untuk melatih model *Machine Learning*. Kliping gradien memecahkan

masalah turunan kesalahan dengan memotong ke nilai ambang batas selama propagasi mundur dalam jaringan. [Tingkat pembelajaran](#) bertanggung jawab atas kecepatan selama mempelajari model.

Tabel 3.3. Parameter penyetelan untuk LSTM dan GRU.

Jumlah fitur	Jumlah respons	Max Epochs	Ambang Gradient	Tingkat Belajar Awal & Jadwal	Pelajari Rate Drop Period & Rate Drop Factor
2	1	250	1	0,005, 'sedikit demi sedikit'	125, 0.2

Jumlah node adalah 128. Jumlah [parameter linier](#) adalah 60. Jumlah [parameter non linear](#) adalah 100. Jumlah total parameter adalah 160. Jumlah pasangan data pelatihan adalah 24. Jumlah pasangan data yang diperiksa adalah 0. Jumlah aturan *fuzzy* adalah 10 [7]. [Tabel 3.4.](#) menampilkan parameter tuning yang dipilih untuk algoritma ANFIS untuk mendapatkan data perkiraan yang lebih akurat dan efisien. Tingkat pembelajaran bertanggung jawab atas kecepatan selama mempelajari model. Jumlah *epochs* menggambarkan jumlah iterasi lengkap dari himpunan data yang akan dijalankan untuk melatih model *Machine Learning*.

3.3. Hasil Simulasi

Kami menggunakan sekelompok kesalahan seperti [Root Mean Square Error](#) (RMSE), *Mean Absolute Error* (MAE) dan [Mean Absolute Percentage Error](#) (MAPE) untuk mengevaluasi efektivitas algoritma yang diusulkan. RMSE, MAE, dan MAPE dapat dihitung dengan rumus:

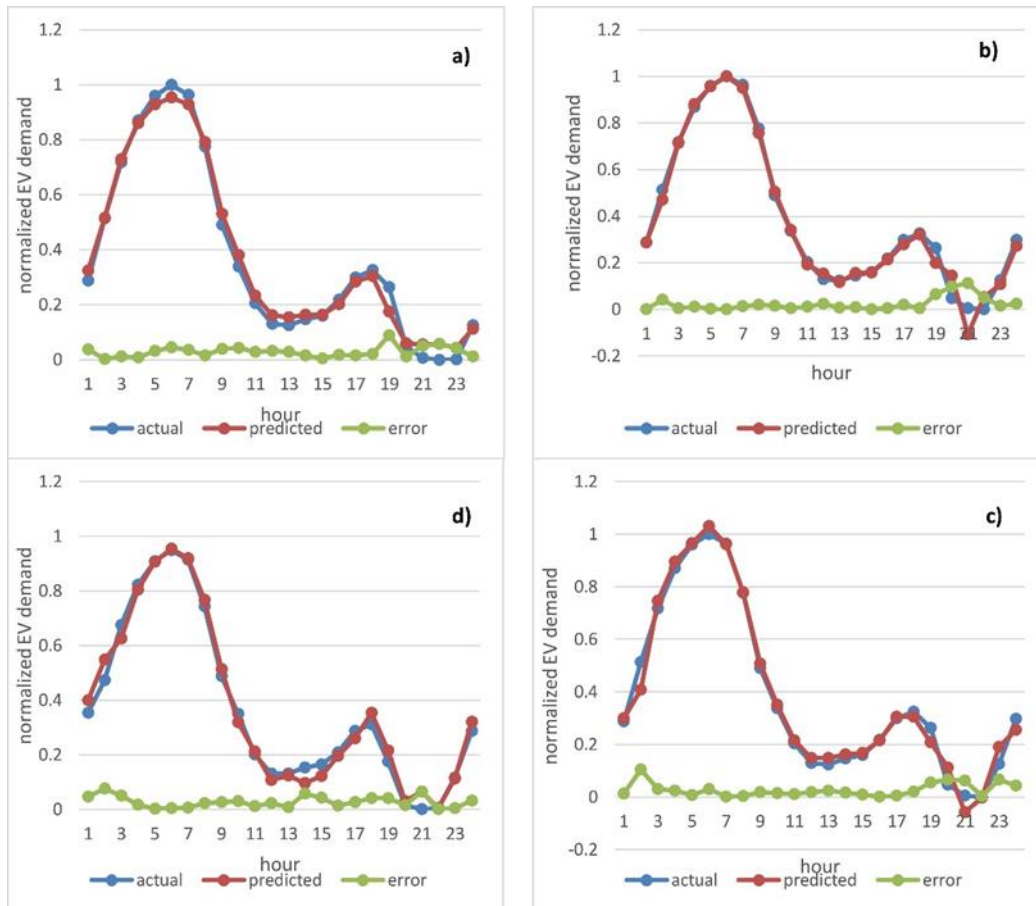
$$RMSE = \sqrt{\frac{1}{N} \sum_{i=1}^N (x_i - y_i)^2} \quad (3.3.1)$$

$$MAE = \frac{1}{N} \sum_{i=1}^N |y_i - x_i| \quad (3.3.2)$$

$$MAPE = \frac{1}{N} \left[\sum_{i=1}^N \left| \frac{y_i - x_i}{x_i} \right| \right] * 100\% \quad (3.3.3)$$

a. Hasil Simulasi untuk Skenario Musim Dingin.

Gambar 3.4. Menunjukkan hasil untuk skenario musim dingin pada Januari 2019 yang menampilkan [dataset pengujian](#) yang dinormalisasi dan nilai prediksi, yang diperoleh dari empat algoritma unggulan yang diusulkan ANN, LSTM, GRU, dan ANFIS masing-masing dibagi menjadi empat bagian dalam satu gambar a, b, c, dan d.



Gambar 4.4. Pengujian dan dataset nilai prediksi pengisian harian rata-rata per jam kendaraan listrik (*electric vehicle*) per bulan setelah pra-pemrosesan data untuk skenario musim dingin, disimulasikan dari ANN, LSTM, GRU, dan ANFIS.

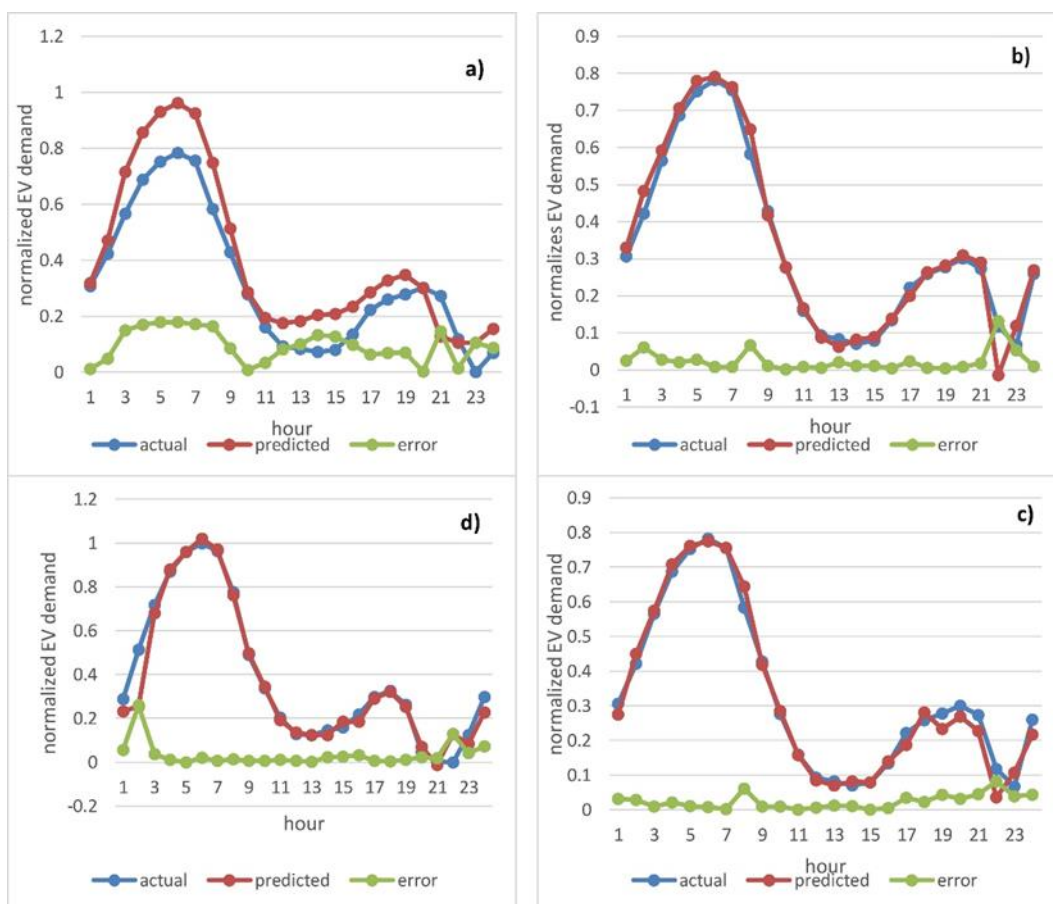
Tabel 3.5. Menampilkan grup kesalahan (RMSE, MAE, dan MAPE) untuk nilai prediksi himpunan data, namun, nilai-nilai ini diperoleh dengan membagi lebih dari 31 hari untuk bulan "Januari" untuk mendapatkan grup kesalahan per jam per hari. Semua hasil diperoleh dan dibandingkan pada faktor Korelasi "R" yang hampir sama.

Tabel 3.5. Ringkasan hasil untuk kelompok kesalahan (RMSE, MAE, dan MAPE) untuk empat algoritma unggulan (NN, LSTM, GRU, dan ANFIS) untuk skenario musim dingin.

	NN	LSTM	GRU	ANFIS
RMSE/hari	0.00155	0.000897	0.001239	0.000209
MAE/hari	0.00124	0.000684	0.000894	0.000919
MAPE/hari	6.75103	4.1870	4.3073	0.56036
R	0.9933	0.9931	0.9932	0.9935

b. Hasil Simulasi untuk Skenario Musim Semi.

Gambar 3.5. Menunjukkan hasil untuk skenario musim semi pada bulan April 2019 yang menampilkan dataset pengujian yang dinormalisasi dan nilai prediksi, yang diperoleh dari empat algoritma unggulan yang diusulkan ANN, LSTM, GRU, dan ANFIS masing-masing.



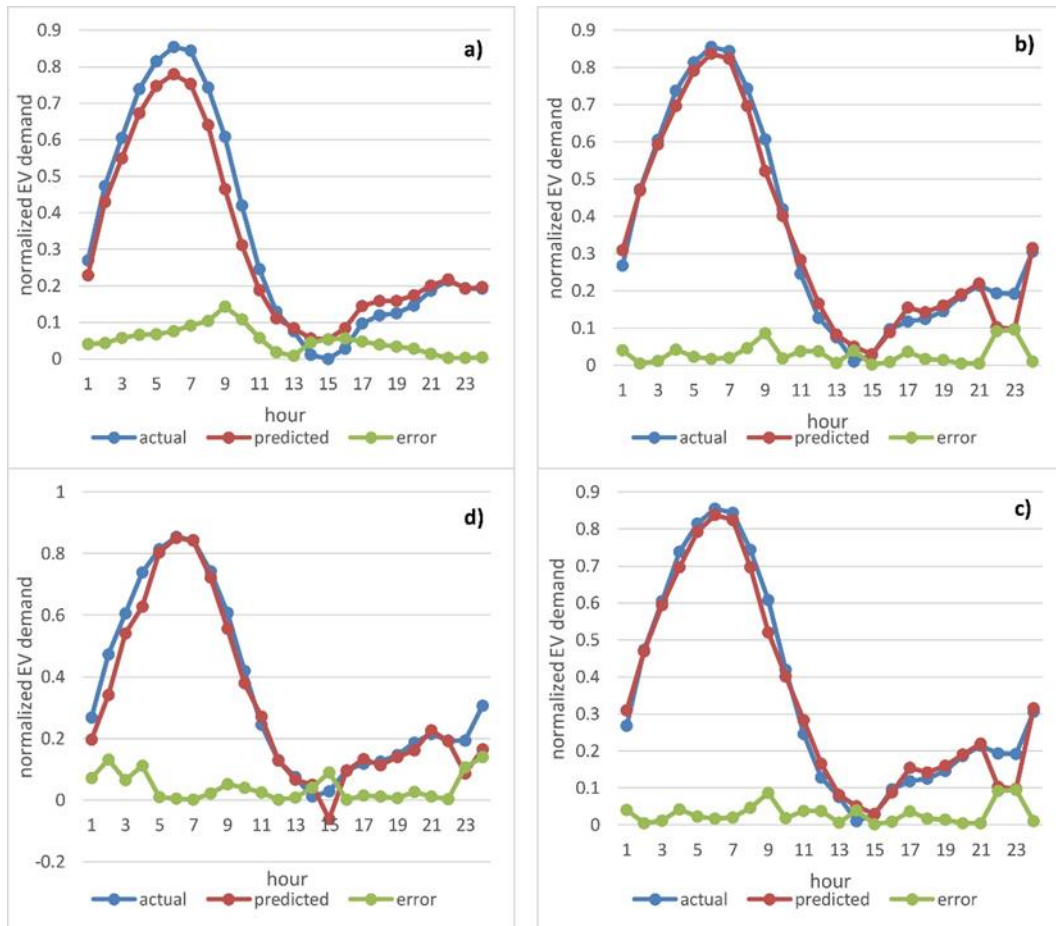
Gambar 3.5. Pengujian dan dataset nilai prediksi pengisian harian rata-rata per jam kendaraan listrik per bulan setelah pra-pemrosesan data untuk skenario musim semi, disimulasikan dari ANN, LSTM, GRU, dan ANFIS.

Tabel 3.6. Ringkasan hasil untuk kelompok kesalahan (RMSE, MAE, dan MAPE) untuk empat algoritma unggulan (NN, LSTM, GRU, dan ANFIS) untuk skenario musim semi.

	NN	LSTM	GRU	ANFIS
RMSE/hari	0.003706	0.0028	0.0022	0.00039
MAE/hari	0.003191	0.0023	0.0017	0.0011
MAPE/hari	1.606235	0.9262	0.6865	0.39592
R	0.9721	0.9777	0.9779	0.9804

c. Hasil Simulasi untuk Skenario Musim Panas.

Gambar 3.6. Menunjukkan hasil untuk skenario musim panas pada Juni 2019 yang menampilkan dataset pengujian yang dinormalisasi dan nilai prediksi, yang diperoleh dari empat algoritma unggulan yang diusulkan ANN, LSTM, GRU, dan ANFIS masing-masing, dibagi menjadi empat bagian dalam satu gambar a, b, c, dan d.



Gambar 3.6. Pengujian dan dataset nilai prediksi pengisian harian rata-rata per jam kendaraan listrik per bulan setelah pra-pemrosesan data untuk skenario musim panas, disimulasikan dari ANN, LSTM, GRU, dan ANFIS.

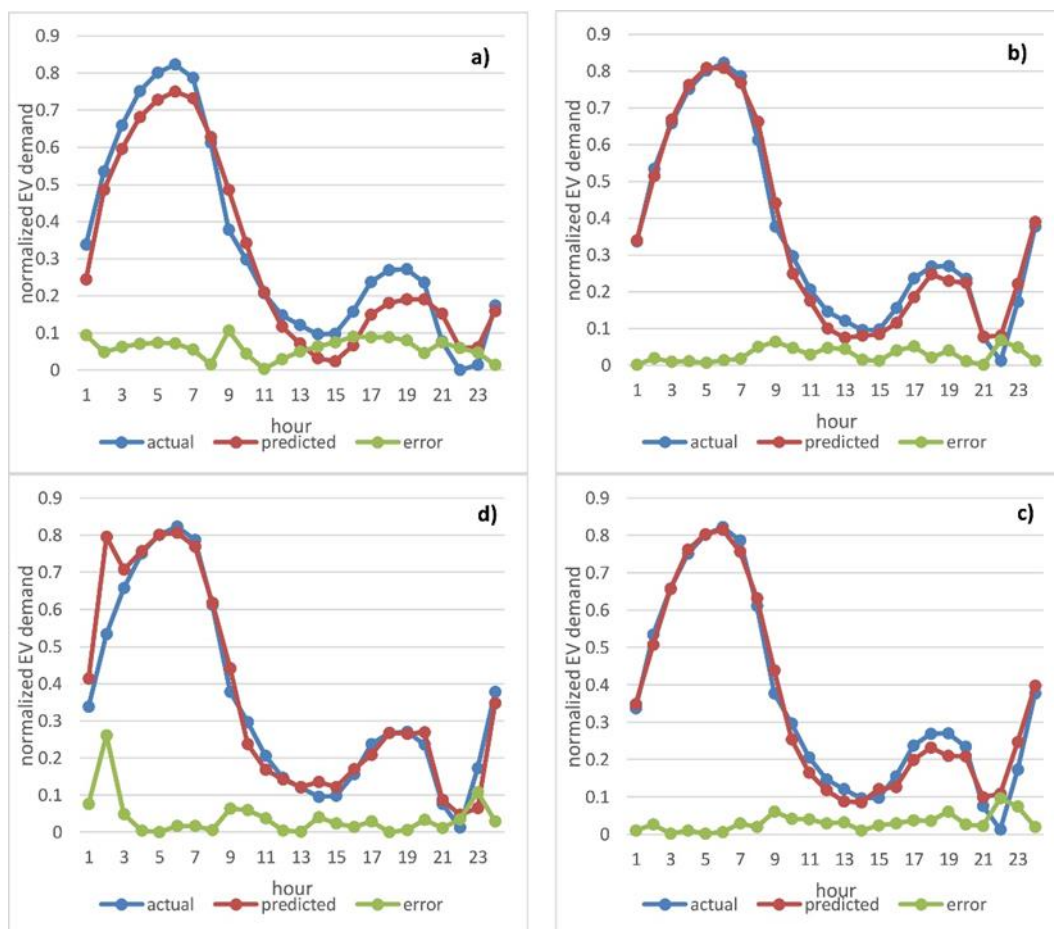
Tabel 3.7. Menampilkan grup kesalahan (RMSE, MAE, dan MAPE) untuk nilai prediksi himpunan data, namun, nilai-nilai ini diperoleh dengan membagi lebih dari 30 hari untuk bulan "Juni" untuk mendapatkan grup kesalahan per jam per hari. Semua hasil diperoleh dan dibandingkan pada faktor korelasi yang hampir sama.

Tabel 3.7. Ringkasan hasil untuk kelompok kesalahan (RMSE, MAE, dan MAPE) untuk empat algoritma unggulan (NN, LSTM, GRU, dan ANFIS) untuk skenario musim panas.

	NN	LSTM	GRU	ANFIS
RMSE/hari	0.00204	0.0025	0.00215	0.00033
MAE/hari	0.00167	0.0019	0.0017	0.0014
MAPE/hari	1.31010	1.2633	1.1898	0.42892
R	0.9917	0.9734	0.9834	0.9856

d. Hasil Simulasi untuk Skenario Musim Gugur.

Gambar 3.7. Menunjukkan hasil untuk skenario musim gugur pada Oktober 2019 yang menampilkan dataset pengujian yang dinormalisasi dan nilai prediksi, yang diperoleh dari empat algoritma unggulan yang diusulkan ANN, LSTM, GRU, dan ANFIS masing-masing, dibagi menjadi empat bagian dalam satu Gambar a, b, c, dan d.



Gambar 3.7. Pengujian dan dataset nilai prediksi pengisian harian rata-rata per jam kendaraan listrik per bulan setelah pra-pemrosesan data untuk skenario musim gugur, disimulasikan dari ANN, LSTM, GRU, dan ANFIS.

Tabel 3.8. Menampilkan grup kesalahan (RMSE, MAE, dan MAPE) untuk nilai prediksi himpunan data, namun, nilai-nilai ini diperoleh dengan membagi lebih dari 31 hari untuk bulan "Oktober" untuk mendapatkan grup kesalahan per jam per hari. Semua hasil diperoleh dan dibandingkan pada faktor korelasi yang hampir sama.

Tabel 3.8. Ringkasan hasil untuk kelompok kesalahan (RMSE, MAE, dan MAPE) untuk empat algoritma unggulan (NN, LSTM, GRU, dan ANFIS) untuk skenario musim gugur.

	NN	LSTM	GRU	ANFIS
RMSE/hari	0.0022	0.00181	0.0019	0.00040
MAE/hari	0.00202	0.0014	0.0016	0.0013
MAPE/hari	1.31874	1.4484	1.6737	0.66382
R	0.9751	0.9822	0.9808	0.97063

Rekap dari gambar 3.4, sebelumnya, Gambar 3.5, Gambar 3.6, Gambar 3.7, dan Tabel 3.5, Tabel 3.6, Tabel 3.7, Tabel 3.8., dapat disimpulkan sebagai berikut:

1. Nilai prediksi dibandingkan dengan nilai aktual dari empat model yang diberikan pada Gambar 3.4, Gambar 3.5, Gambar 3.6, [Gambar 3.7](#), yang menunjukkan hasil dalam data pengujian, di mana AREP dilambangkan sebagai titik kesalahan nyata absolut.
2. Kesalahan absolut menunjukkan perbedaan absolut antara nilai aktual dan nilai prediksi.
3. Di musim dingin, Gambar 3.4:

- a. Nilai yang diperkirakan dari ANN secara signifikan mendekati nilai aktual kecuali pada jam 1, 5-7, 12-13, dan 21-23 dengan AREP tertinggi pada jam 19.
 - b. Nilai yang diperkirakan dari LSTM secara signifikan mendekati nilai aktual kecuali pada jam 20-22 dengan AREP tertinggi pada jam 21.
 - c. Nilai yang diperkirakan dari GRU secara signifikan mendekati nilai aktual kecuali pada jam 2, 19-23 dengan AREP tertinggi pada jam 2.
 - d. Nilai yang diperkirakan dari ANFIS secara signifikan mendekati nilai aktual kecuali pada jam 1-2, 14-15, dan 21 dengan AREP tertinggi pada jam 2.
4. Di musim semi, Gambar 3.5:
- a. Nilai yang diperkirakan dari ANN sedikit mendekati nilai aktual dengan AREP tertinggi dalam 24 jam.
 - b. Nilai perkiraan dari LSTM secara signifikan mendekati nilai aktual kecuali pada jam 22 dengan AREP tertinggi pada jam 22.
 - c. Nilai yang diperkirakan dari GRU secara signifikan mendekati nilai aktual kecuali pada jam 19-23 dengan AREP tertinggi pada jam 22.
 - d. Nilai perkiraan dari ANFIS secara signifikan mendekati nilai aktual kecuali pada jam 1-2, dan 22-24 dengan AREP tertinggi pada jam 22.
5. Di musim panas, Gambar 3.6:
- a. Nilai yang diperkirakan dari ANN sedikit mendekati nilai aktual dengan AREP tertinggi dalam 24 jam.
 - b. Nilai yang diperkirakan dari LSTM secara signifikan mendekati nilai aktual kecuali pada jam 1, 9, 17, 22-23 dengan AREP tertinggi pada jam 23.
 - c. Nilai yang diperkirakan dari GRU secara signifikan mendekati nilai aktual kecuali pada jam 1, 9, 17, 22-23 dengan AREP tertinggi pada jam 23.
 - d. Nilai yang diperkirakan dari ANFIS secara signifikan mendekati nilai aktual kecuali pada jam 1-6, 15, dan 23-24 dengan AREP tertinggi pada jam 24.
6. Di musim gugur, Gambar 3.7:
- a. Nilai yang diperkirakan dari ANN sedikit mendekati nilai aktual dengan AREP tertinggi dalam 24 jam.
 - b. Nilai yang diperkirakan dari LSTM secara signifikan mendekati nilai aktual kecuali pada jam 1, 9, 17, 22-23 dengan AREP tertinggi pada jam 23.
 - c. Nilai yang diperkirakan dari GRU secara signifikan mendekati nilai aktual kecuali pada jam 1, 9, 17, 22-23 dengan AREP tertinggi pada jam 23.
 - d. Nilai yang diperkirakan dari ANFIS secara signifikan mendekati nilai aktual kecuali pada jam 1-6, 15, dan 22-23 dengan AREP tertinggi pada jam 24.
7. Di musim gugur, Gambar 3.8:
- a. Nilai yang diperkirakan dari ANN sedikit mendekati nilai aktual dengan AREP tertinggi dalam 24 jam.
 - b. Nilai yang diperkirakan dari LSTM secara signifikan mendekati nilai aktual kecuali pada jam 11-20, dan 22 dengan AREP tertinggi pada jam 22.
 - c. Nilai yang diperkirakan dari GRU secara signifikan mendekati nilai aktual kecuali pada jam 11-13, 17-19, dan 22-23 dengan AREP tertinggi pada jam 22.
 - d. Nilai yang diperkirakan dari ANFIS secara signifikan mendekati nilai aktual kecuali pada jam 2 dengan AREP tertinggi pada jam 2.
8. Dapat dilihat bahwa AREP adalah yang tertinggi pada Gambar 3.5, sedangkan AREP yang terendah pada Gambar 3.7. selama beban puncak yang dicapai pada pukul 6 pagi pada hari terakhir tahun ini yang dilambangkan sebagai hari musim semi dan musim gugur.
9. Membandingkan hasil yang diperoleh dari mesin *Deep Learning* pada Tabel 3.5, 3.6, 3.7, dan 3.8:
- a. Terlihat bahwa algoritma GRU lebih baik dalam kinerja dengan sekelompok kesalahan yang kurang dari LSTM dengan sedikit peningkatan faktor korelasi (R).
 - b. Hasil yang diperoleh dari mesin *Machine Learning* menunjukkan bahwa algoritma ANFIS lebih baik kinerjanya dengan sekelompok kesalahan yang lebih kecil dari ANN dengan peningkatan faktor korelasi R yang signifikan.
 - c. Hasil yang diekstrak dari algoritma yang diusulkan (ANFIS) membuktikan efisiensi dan akurasinya untuk hasil *Neural Network* (NN), *Long Short-Term Memory* (LSTM), dan *Gated Recurrent Unit* (GRU) dengan faktor korelasi terbaik R di antara ketiga algoritma lainnya.
 - d. Membandingkan hasil yang diperoleh dari dua musim di musim dingin dan musim panas, terlihat bahwa MAPE di musim panas sedikit lebih baik dan kurang dari MAPE di musim dingin yang disimulasikan dari empat algoritma.
-

- e. Membandingkan hasil yang diperoleh dari dua musim di musim semi dan musim gugur, terlihat bahwa MAPE di musim semi secara signifikan lebih baik dan kurang dari MAPE di musim dingin, yang disimulasikan dari tiga algoritma, yaitu LSTM, GRU, dan ANFIS. Sedangkan MAPE di musim semi sedikit lebih tinggi dari MAPE di musim gugur yang disimulasikan dari ANN.
- f. Hasil ANFIS (RMSE, MAPE) yang diperoleh pada musim gugur adalah yang terburuk dengan faktor korelasi terburuk R di antara hasil keseluruhan yang diperoleh dalam tiga musim lainnya.
- g. Hasil ANFIS (RMSE, MAPE) yang diperoleh pada musim semi adalah yang terbaik dengan nilai moderat faktor korelasi R di antara hasil keseluruhan yang diperoleh pada tiga musim lainnya.
10. Dari hasil yang disimpulkan, ada beberapa poin yang harus diselidiki untuk pekerjaan di masa depan:
 - a. Model peramalan khusus untuk terjadinya lonjakan karena efek musim yang berbeda, dengan mempertimbangkan lebih banyak faktor selain faktor empat musim seperti kalender, produk domestik bruto (PDB), harga listrik, dan kebijakan pasar harus dilakukan.
 - b. Menghadapi parameter dari empat algoritma unggulan untuk mendapatkan nilai perkiraan dengan MAPE paling sedikit atau dengan menggabungkan lebih banyak algoritma *Machine Learning* dan *Deep Learning* dengan yang saat ini digunakan seperti jaringan syaraf tiruan adaptif, algoritma [genetika](#) adaptif (AGA-LSTM), dan ANFIS hibridasi dengan algoritma [metaheuristik](#) lainnya seperti [particle swarm optimization](#) (PSO) dan [algoritma whale optimization](#) (WOA) harus dinavigasi.

4. KESIMPULAN

4.1. Kesimpulan

Model peramalan beban dianggap sebagai solusi utama karena peningkatan dramatis dalam jumlah kendaraan listrik dengan perilaku pengisian online yang menyebabkan peningkatan jumlah data. Dalam studi ini, model-model baru dengan metodologi konser yang menjanjikan yang meningkatkan kecepatan dan akurasi prediksi diantisipasi. Empat algoritma yang diusulkan diterapkan untuk memperkirakan permintaan rata-rata per jam selama efek empat musim. Di mana model peramalan telah dipengaruhi oleh faktor empat musim, diwakili dalam rentang suhu, yang memiliki dampak besar pada profil beban kendaraan listrik dalam pengisian dan pengurusan baterai yang bergantung pada penumpang kendaraan listrik karena menggunakan [AC](#) dan pemanas. Empat algoritma unggulan digunakan dalam penelitian lain yang menyangkut fluktuasi suhu seperti *Artificial Neural Network* (ANN), *Long Short-Term Memory* (LSTM), *Gated Recurrent Unit* (GRU), dan *Adaptive Neuro Fuzzy Inference System* (ANFIS). Algoritma yang disebutkan sebelumnya ini telah mengusulkan kerangka kerja peramalan yang lebih kuat dan akurat dengan kelompok kesalahan paling sedikit. Dengan menerapkan algoritma *Deep Learning*, dataset prakiraan yang diperoleh dari algoritma *Gated Recurrent Unit* lebih akurat dengan rata-rata *Absolute Percentage Error* (MAPE) yang lebih sedikit daripada hasil yang diperoleh dari algoritma *Long Short-Term Memory*. Ini karena itu MAPE akumulatif dalam 24 jam telah menurun masing-masing sebesar 0,1203%, 0,2397%, dan 0,0735% dengan akurasi masing-masing 99,3%, 97,7%, dan 98,3% di musim dingin, musim semi, dan musim panas. Namun, MAPE akumulatif meningkat sebesar 0,2253% dengan akurasi 98,08% di musim gugur. Untuk algoritma [Machine Learning](#), himpunan data yang diperkirakan diperoleh dari inferensi *neuro-fuzzy* adaptif lebih akurat dengan kesalahan persentase absolut rata-rata yang lebih sedikit daripada hasil yang diperoleh dari algoritma Jaringan Syaraf Tiruan. Hal ini karena bahwa MAPE akumulatif dalam 24 jam telah menurun sebesar 6,1907%, 1,2103%, 0,8812%, dan 0,7236% dengan akurasi masing-masing 99,35%, 98,04%, 98,56%, dan 97,06% di musim dingin, musim semi, musim panas, dan musim gugur. Oleh karena itu, algoritma *Adaptive Neuro Fuzzy Inference System* membuktikan bahwa dataset yang diperkirakan adalah yang paling akurat dan kinerja terbaik dengan kesalahan persentase absolut rata-rata akumulatif paling sedikit di antara algoritma lain yang diusulkan. Namun, hasil yang diperoleh dari ANFIS secara signifikan dipengaruhi oleh efek empat musim dari pengisian permintaan kendaraan listrik (*electric vehicle*) per jam.

4.2. Saran

Studi ini berusaha untuk memperkirakan kendaraan listrik per jam yang mengisi listrik per hari dalam empat musim dan di mana efek empat musim (suhu dan sifat konsumsi pemilik kendaraan listrik) mempengaruhi pengisian dan drainase baterai kendaraan listrik. Dalam pekerjaan masa depan dan studi selanjutnya:

1. Kami akan menyelidiki efek karakteristik pada prediksi yang lebih rinci seperti kalender, produk domestik bruto (PDB), harga listrik, dan kebijakan pasar.

2. Peramalan jangka panjang juga dapat membantu dalam peningkatan perencanaan kota.
3. Selain memprediksi pengisian dan pemakaian kendaraan listrik, kami juga dapat menyertakan [sumber daya terbarukan](#) seperti energi angin dan matahari.
4. Untuk jangka waktu pelatihan yang panjang dan banyak parameter, algoritma *Deep Learning* sering dikritik. Efisiensi algoritma tidak diragukan lagi akan meningkat melalui penelitian tentang meminimalkan parameter dan waktu pelatihan.
5. Penting untuk menavigasi perubahan parameter dari empat algoritma unggulan untuk mendapatkan nilai perkiraan dengan MAPE paling sedikit atau dengan menggabungkan lebih banyak algoritma pembelajaran mesin dan mendalam dengan yang sudah digunakan, seperti jaringan syaraf tiruan adaptif, algoritma [genetika](#) adaptif (AGA-LSTM), dan ANFIS hibridisasi dengan [algoritma metaheuristik](#) lainnya, seperti [particle swarm optimization](#) (PSO), dan [algoritma whale optimization](#) (WOA).





UCAPAN TERIMA KASIH

Terima kasih kepada Allah SWT yang telah memberikan rahmat dan hidayahnya kepada kita semua sehingga peneliti dapat melakukan penelitian ini dengan baik. Terima kasih saya ucapkan kepada dosen pengajar mata kuliah Metodologi Penelitian Teknologi Informasi (MPTI) yaitu Bapak Riad Sahara, S.SI., M.T. yang telah memberikan materi perkuliahan dari pertemuan ke satu hingga pertemuan ke enam belas dengan sempurna. Sehingga kami dapat memahami dan menjadi mengerti lebih dalam tentang apa itu Metodologi Penelitian Teknologi Informasi. Terima kasih juga saya ucapkan kepada Bapak Muhammad Ikhwan Saputra S.Kom., M.Kom selaku dosen pembimbing, semoga beliau mendapatkan perlindungan dari Tuhan Yang Maha Esa dalam menjalankan semua aktifitasnya sehingga dapat berjalan dengan lancar tanpa gangguan apapun. Terima kasih kepada teman-teman yang telah membantu dalam menyelesaikan penelitian ini hingga selesai. Peneliti berharap masukan dari teman-teman dan pihak lainnya guna kesempurnaan dalam melakukan penelitian selanjutnya. Terima kasih.

REFERENSI

- [1] Definisi dan Dasar-dasar Engine. (2013, Oktober 18). Diambil kembali dari MARITIME WORLD: <https://www.maritimeworld.web.id/2013/10/definisi-dan-dasar-dasar-engine.html>. Diakses pada tanggal 19 November 2023.
- [2] Pengertian Engine Dalam Dunia Otomotif. (2023, September 3). Diambil kembali dari Planet Ban: <https://planetban.com/blog/pengertian-engine-dalam-dunia-otomotif>. Diakses pada tanggal 19 November 2023.
- [3] Dr. Suyanto, S. M. (2019). *Deep Learning Modernisasi Machine Learning untuk Big Data*. Bandung: INFORMATIKA.
- [4] Zakky. (2020, Februari 23). Pengertian Analisis Menurut Para Ahli dan Secara Umum . Diambil kembali dari ZonaReferensi.com: <https://www.zonareferensi.com/pengertian-analisis-menurut-para-ahli-dan-secara-umum/>. Diakses pada tanggal 19 November 2023.
- [5] W, F. (2023, Januari 18). Apa Itu DBMS? Pengertian, Jenis, dan Contoh DBMS. Diambil kembali dari Hostinger Tutorial: <https://www.hostinger.co.id/tutorial/dbms-adalah>. Diakses tanggal 22 November 2023.
- [6] Fikriansyah, I. (2023, Juli 11). Algoritma Adalah: Pengertian, Ciri-ciri, dan Berbagai Jenisnya. Diambil kembali dari detikedu: <https://www.detik.com/edu/detikpedia/d-6817970/algoritma-adalah-pengertian-ciri-ciri-dan-berbagai-jenisnya>. Diakses tanggal 22 November 2023.
- [7] Hebba-Allah, El-Azab, R. S.-A. (2023, Oktober). Seasoning electric vehicle forecasting model based on machine learning and Deep Learning techniques. Diambil kembali dari ScienceDirect: <https://doi.org/10.1016/j.egyai.2023.100285>. Diakses tanggal 5 November 2023.
- [8] Tai-Yu Ma, S. F. (2022, April 1). Multistep electric vehicle charging station occupancy prediction using hybrid LSTM neural networks. Diambil kembali dari ScienceDirect: <https://doi.org/10.1016/j.energy.2022.123217>. Diakses tanggal 5 November 2023.
- [9] Mouaad Boulakhbar, M. F. (2022, Desember). A deep learning approach for prediction of electrical vehicle charging stations power demand in regulated electricity markets: The case of Morocco. Diambil kembali dari ScienceDirect: <https://doi.org/10.1016/j.cles.2022.100039>. Diakses tanggal 5 November 2023.
- [10] Andrey Poddubnyy, P. N. (2023, Desember). Online EV charging controlled by reinforcement learning with experience replay. Diambil kembali dari ScienceDirect: <https://doi.org/10.1016/j.segan.2023.101162>. Diakses tanggal 5 November 2023.
- [11] Sooji Ha, D. J. (2021, Januari 22). Topic classification of electric vehicle consumer experiences with transformer-based deep learning. Diambil kembali dari ScienceDirect: <https://doi.org/10.1016/j.patter.2020.100195>. Diakses tanggal 5 November 2023.
- [12] Silva, V. B. (2020). Monte Carlo Approach. Retrieved from ScienceDirect: <https://www.sciencedirect.com/topics/engineering/monte-carlo-approach>. Diakses tanggal 06 Februari 2024.
- [13] Manfred Gilli, E. S. (2019). *Markov Chain*. Retrieved from ScienceDirect: <https://www.sciencedirect.com/topics/computer-science/markov-chain>. Diakses tanggal 06 Februari 2024.
- [14] Anoop Kodakkal, V. M. (2020). Stochastic response of primary–secondary coupled systems under uncertain ground excitation using generalized polynomial chaos method). *Stochastic response of primary–secondary coupled systems under uncertain ground excitation using generalized polynomial chaos method*. Retrieved from Science Direct: <https://www.sciencedirect.com/science/article/abs/pii/B9780128165140000163>. Diakses tanggal 06 Februari 2024.
- [15] Hassan Z. Al Garmi, A. A. (2020). Pendekatan Monte Carlo diterapkan pada analisis sensitivitas dampak kriteria pada pemilihan lokasi PV surya. Retrieved from Science Direct: <https://www.sciencedirect.com/science/article/abs/pii/B9780128165140000205>. Diakses tanggal 06 Februari 2024.
- [16] K.A. Venkatesh, V. P. (2023). *Regression tasks for machine learning*. Retrieved from Science Direct: <https://www.sciencedirect.com/topics/engineering/coefficient-variance>. Diakses tanggal 06 Februari 2024.
- [17] Debesh Shankar Tripathy, B. R. (2021). *Forecasting of renewable generation for applications in smart grid power systems*. Retrieved from Science Direct: <https://www.sciencedirect.com/topics/engineering/quantile>. Diakses tanggal 06 Februari 2024.

BIOGRAFI PENULIS

	<p>Hendro Gunawan    lahir di Jakarta, pada tanggal 1 Januari 1981. Menyelesaikan pendidikan Taman Kanak-Kanak (TK) dan Sekolah Dasar (SD) di Desa Sumber Sari Kecamatan Sine Kabupaten Ngawi Jawa Timur, kemudian Sekolah Menengah Pertama (SMP), dan Sekolah Menengah Atas (SMA) di kabupaten Muara Enim Provinsi Sumatra Selatan. Saat ini sedang menempuh pendidikan S1 jurusan PJJ Informatika di Universitas Siber Asia (UNSIA) Jakarta. Selain sebagai mahasiswa, penulis juga aktif sebagai karyawan di PT Indospring Tbk. Penulis juga menyukai bahasa pemrograman PHP, <i>Java</i>, Lua, dan Python. Dengan membaca penelitian ini penulis berharap dapat menambah pengetahuan dan <i>skill</i> dalam bidang Metodologi Penelitian Teknologi Informasi (MPTI) terutama yang menggunakan metodologi kualitatif dan kuantitatif sehingga kita dapat menjadi seorang peneliti yang hebat. Penulis dapat dihubungi melalui Telp: 081259640815, Email: hendro.gnwn@gmail.com, hendro.gnwn@ymail.com, hendro.gnwn@outlook.com</p>
---	---